

# Graph Neural Networks and Graph Convolutional Networks

Carlos Puigserver

Germán Llorente

November 19, 2023

## Implementación

En esta sección, se presenta la implementación de Graph Neural Networks (GNN) y redes convolucionales gráficas (GCN) utilizando PyTorch Geometric. Se ha utilizado un entorno específico y un conjunto de datos hipotético de documentos para la tarea de clasificación.

## Entorno y Configuración Inicial

### Entorno de Desarrollo

La implementación se llevó a cabo en un entorno de desarrollo basado en Python utilizando Jupyter Notebook. Se utilizó Python 3.8 y las siguientes bibliotecas principales:

```
$ pip install torch  
$ pip install torch-geometric
```

### Configuración Inicial

Se creó un script de Python en un entorno virtual para garantizar la independencia del entorno. A continuación, se presenta un resumen de la configuración inicial:

```
# Activar el entorno virtual  
$ source venv/bin/activate  
  
# Instalar bibliotecas necesarias  
(venv) $ pip install torch  
(venv) $ pip install torch-geometric
```

## Experimentación con Conjunto de Datos de Documentos

Se utilizó un conjunto de datos hipotético que contiene documentos representados como grafos. Cada nodo del grafo representa una palabra en el documento, y los enlaces entre nodos indican relaciones semánticas entre palabras. El objetivo es clasificar los documentos en categorías específicas.

## Carga y Exploración del Conjunto de Datos

El conjunto de datos se cargó utilizando PyTorch Geometric y se exploró para comprender su estructura:

```
1 from torch_geometric.datasets import DocumentsDataset
2
3 # Cargar el conjunto de datos de documentos
4 document_dataset = DocumentsDataset(
5     root='path/to/document_dataset', download=True
6 )
7
8 # Explorar el conjunto de datos
9 print(f'Número de documentos en el conjunto de datos: {len(
10     document_dataset)}')
11
12 # Visualizar un ejemplo de grafo representando un documento
13 document_graph = document_dataset[0]
14 print(document_graph)
```

## Definición del Modelo GNN y GCN

Se implementó un modelo GNN con una capa GCN para la clasificación de documentos. La arquitectura del modelo se diseñó de acuerdo con las características del conjunto de datos.

```
1 import torch
2 import torch.nn as nn
3 import torch.nn.functional as F
4 from torch_geometric.nn import GCNConv
5
6 class DocumentGNN(nn.Module):
7     def __init__(self, in_channels, out_channels, num_classes):
8         super(DocumentGNN, self).__init__()
9         self.conv1 = GCNConv(in_channels, out_channels)
10        self.conv2 = GCNConv(out_channels, num_classes)
11
12    def forward(self, data):
13        x, edge_index = data.x, data.edge_index
14
15        x = F.relu(self.conv1(x, edge_index))
16        x = F.dropout(x, training=self.training)
17        x = self.conv2(x, edge_index)
18
19        return F.log_softmax(x, dim=1)
```

## Entrenamiento del Modelo

El modelo se entrenó utilizando un procedimiento de entrenamiento estándar. Se definieron funciones de pérdida y se utilizó el optimizador Adam.

```

1 from torch_geometric.data import DataLoader
2 import torch.optim as optim
3
4 # Parámetros de entrenamiento
5 lr = 0.01
6 epochs = 50
7
8 # Configuración del DataLoader
9 train_loader = DataLoader(document_dataset, batch_size=32, shuffle=True)
10
11 # Inicialización del modelo y del optimizador
12 model = DocumentGNN(in_channels=64, out_channels=128, num_classes=10)
13 optimizer = optim.Adam(model.parameters(), lr=lr)
14
15 # Función de pérdida
16 criterion = nn.NLLLoss()
17
18 # Ciclo de entrenamiento
19 for epoch in range(epochs):
20     model.train()
21     for data in train_loader:
22         optimizer.zero_grad()
23         output = model(data)
24         loss = criterion(output, data.y)
25         loss.backward()
26         optimizer.step()
27
28     # Imprimir información de entrenamiento
29     print(f'poca {epoch + 1}/{epochs}, P rdida: {loss.item()}')

```

Este ejemplo hipotético proporciona una visión general de la implementación de GNN y GCN para la clasificación de documentos utilizando PyTorch Geometric. Los detalles específicos, como la arquitectura del grafo, la estructura del conjunto de datos y los parámetros del modelo, deben ajustarse según los requisitos de la tarea y el conjunto de datos específicos.